

**BỘ TÀI CHÍNH
TRƯỜNG ĐẠI HỌC TÀI CHÍNH – MARKETING
KHOA KHOA HỌC DỮ LIỆU
...oOo...**



**BÁO CÁO HỌC PHẦN
MÁY HỌC VÀ TRÍ TUỆ NHÂN TẠO**

**ỨNG DỤNG MACHINE LEARNING ĐỂ DỰ ĐOÁN VÀ
GIẢM THIỂU TỶ LỆ RỜI BỎ DỊCH VỤ**

Giảng viên hướng dẫn: PGS.TS. Nguyễn Tuấn Duy

Mã môn học : 2611101168309

Mã số sinh viên : 2321003593

Sinh viên thực hiện: Phạm Ngọc Thế Kiên

Thành phố Hồ Chí Minh - Ngày 20 tháng 4 năm 2026

[illegible]

MỤC LỤC

MỤC LỤC	iii
LỜI CẢM ƠN	v
DANH MỤC CÁC HÌNH ẢNH.....	vi
DANH MỤC CÁC BẢNG BIỂU.....	vii
MỞ ĐẦU.....	1
1.1. Bối cảnh bài toán	1
1.2. Mục tiêu nghiên cứu	1
1.3. Đối tượng và phạm vi dữ liệu	1
1.4. Bố cục của đề tài.....	2
CHƯƠNG 1. TỔNG QUAN VỀ BÁO CÁO	3
1.1. Tổng quan về bài toán dự đoán khách hàng rời bỏ.....	3
1.2. Tổng quan về bộ dữ liệu Telco Customer Churn	3
1.3. Hệ thống thư viện phân tích và học máy	5
1.4. Các mô hình học máy được áp dụng	6
1.5. Các chỉ số đánh giá hiệu năng mô hình	8
CHƯƠNG 2: KHÁM PHÁ VÀ PHÂN TÍCH DỮ LIỆU.....	10
2.1. Đọc và mô tả ban đầu về dữ liệu	10
2.2. Kiểm tra cấu trúc và chất lượng dữ liệu	10
2.3. Phân bố biến mục tiêu Churn.....	11
2.4. Phân tích biến phân loại theo Churn.....	11
2.5. Phân tích biến số theo Churn	14
2.6. Phân tích chi phí trung bình theo nhóm thời gian gắn bó.....	15
CHƯƠNG 3. TIỀN XỬ LÝ DỮ LIỆU.....	17
3.1. Xử lý dữ liệu thiếu và không hợp lệ	17
3.2. Chia tập huấn luyện và kiểm tra	17
3.3. Mã hóa biến phân loại (One-Hot Encoding).....	18
3.4. Chuẩn hóa dữ liệu (StandardScaler)	18
3.5. Chiến lược tiền xử lý toàn diện.....	18
CHƯƠNG 4: XÂY DỰNG MÔ HÌNH HỌC MÁY	20

4.1. Thiết kế bài toán và lựa chọn thuật toán.....	20
4.2. Tối ưu hóa siêu tham số bằng GridSearchCV	20
4.3. Kết quả đánh giá và so sánh mô hình	21
4.4. Lựa chọn mô hình tốt nhất.....	24
4.5. Đánh giá chi tiết mô hình Random Forest	24
4.6. Feature Importance và Insight kinh doanh	25
4.6.1. Phân tích Feature Importance từ mô hình Random Forest.....	25
4.6.2. Insight kinh doanh sâu từ Feature Importance.....	27
4.6.3. Đề xuất hành động kinh doanh cụ thể.....	28
CHƯƠNG 5: KẾT LUẬN & KIẾN NGHỊ	30
5.1. Tóm tắt kết quả đạt được	30
5.2. Kiến nghị thực tế cho doanh nghiệp	30
TÀI LIỆU THAM KHẢO.....	32

LỜI CẢM ƠN

Trước hết, em xin trân trọng gửi lời cảm ơn đến Trường Đại học Tài chính-Marketing đã tạo điều kiện về cơ sở vật chất và mang đến môn máy học và trí tuệ nhân tạo này cùng với chương trình giảng dạy vô cùng bài bản và khoa học. Bên cạnh đó, nhà trường còn giúp chúng em tiếp cận với những tài liệu, bài giảng. Đây là nguồn tài nguyên quan trọng, hỗ trợ rất nhiều trong quá trình nghiên cứu và phát triển nội dung bài tập lớn này.

Em xin cảm ơn và hơn thế là biết ơn sâu sắc đến thầy Nguyễn Tuấn Duy- giảng viên hướng dẫn bộ môn máy học và trí tuệ nhân tạo đã tận tình chỉ dạy, cung cấp những kiến thức quý báu và thiết thực bằng tất cả tâm huyết của mình. Sự hỗ trợ của thầy không chỉ dừng lại ở việc hướng dẫn, trao đổi mà còn vạch ra đường đi nước bước trong quá trình lĩnh hội, tích lũy kiến thức từ môn học quan trọng này. Những quan điểm và những phản hồi từ thầy giúp em mở rộng tầm nhìn, có nhiều ý tưởng hơn để từ đó nghiên cứu một cách hiệu quả.

Tuy nhiên, do vốn kiến thức còn nhiều hạn chế và khả năng tiếp thu thực tế còn nhiều bỡ ngỡ nên em khó có thể tránh khỏi những thiếu sót và một số chỗ còn chưa chính xác, kính mong thầy xem xét và góp ý để bài báo cáo của em được hoàn thiện hơn.

Một lần nữa, em xin cảm ơn và kính chúc thầy nhiều sức khỏe và gặt hái được nhiều thành công trong cuộc sống.

Trân trọng!

DANH MỤC CÁC HÌNH ẢNH

Biểu đồ 2. 1: Phân bố số lượng và tỷ lệ khách hàng theo nhãn Churn.....	11
Biểu đồ 2. 2: Biểu đồ Churn theo từng biến phân loại (18 biểu đồ nhóm)	13
Biểu đồ 2. 3: Boxplot phân bố biến số tenure, MonthlyCharges và TotalCharges theo Churn	15
Biểu đồ 2. 4: Biểu đồ chi phí trung bình theo nhóm Tenure_Group và nhãn Churn	16
Hình ảnh 4. 1: Báo cáo Đánh giá Mô hình Dự đoán	22
Hình ảnh 4. 2: Đánh giá hiệu suất mô hình Random Forest	24
Hình ảnh 4. 3: Biểu đồ đặc trưng quan trọng của các biến	26

DANH MỤC CÁC BẢNG BIỂU

Bảng 1. 1: Mô tả các cột trong bộ dữ liệu Telco Customer Churn	4
Bảng 2. 1: Thống kê số lượng giá trị thiếu và không hợp lệ theo từng cột.....	10
Bảng 3. 1: Chiến lược tiền xử lý dữ liệu theo từng bước	18
Bảng 4. 1: Các mô hình học máy được lựa chọn và lý do.....	20
Bảng 4. 2: Không gian tìm kiếm siêu tham số cho từng mô hình	21
Bảng 4. 3: Đề xuất hành động kinh doanh từ kết quả phân tích	28

MỞ ĐẦU

1.1. Bối cảnh bài toán

Trong bối cảnh ngành viễn thông ngày càng cạnh tranh gay gắt, việc giữ chân khách hàng hiện hữu đã trở thành ưu tiên chiến lược hàng đầu của các doanh nghiệp. Theo nhiều nghiên cứu trong lĩnh vực quản trị khách hàng, chi phí để thu hút một khách hàng mới thường cao hơn từ năm đến bảy lần so với chi phí duy trì một khách hàng đã có. Điều này đồng nghĩa với việc mỗi khách hàng quyết định rời bỏ dịch vụ đều gây ra tổn thất kép: không chỉ mất đi dòng doanh thu trực tiếp, mà còn đòi hỏi một khoản chi phí đáng kể để tìm kiếm khách hàng thay thế.

Trước thực trạng đó, việc xây dựng một hệ thống có khả năng phát hiện sớm những khách hàng có nguy cơ rời bỏ, từ đó hỗ trợ đội ngũ chăm sóc khách hàng can thiệp kịp thời, đã trở thành một yêu cầu thực tiễn cấp thiết. Học máy cung cấp một nền tảng kỹ thuật mạnh mẽ để giải quyết bài toán này, thông qua khả năng học hỏi các mẫu ẩn trong dữ liệu lịch sử và dự đoán hành vi trong tương lai với độ chính xác cao.

Xuất phát từ những lý do trên, em quyết định chọn đề tài: "*Ứng dụng machine learning để dự đoán và giảm thiểu tỷ lệ rời bỏ dịch vụ*". Đây không chỉ là một bài tập ứng dụng kỹ thuật, mà còn là nỗ lực của nhóm trong việc kiến tạo một quy trình phân tích dữ liệu hoàn chỉnh, từ khám phá dữ liệu thô cho đến đề xuất chiến lược can thiệp kinh doanh có căn cứ. Một mô hình dự đoán churn chính xác cho phép doanh nghiệp chuyển từ thế bị động sang thế chủ động can thiệp trước khi quyết định được đưa ra.

1.2. Mục tiêu nghiên cứu

Đề án đặt ra các câu hỏi nghiên cứu cụ thể sau:

Yếu tố nào như nhân khẩu học, loại dịch vụ, phương thức thanh toán, thời gian gắn bó ảnh hưởng mạnh nhất đến quyết định rời bỏ của khách hàng?

Mô hình phân loại nào K-Nearest Neighbors, Logistic Regression, SVM hay Random Forest cho hiệu năng tốt nhất trên bộ dữ liệu này?

Kết quả mô hình dịch sang các đề xuất hành động kinh doanh cụ thể như thế nào?

1.3. Đối tượng và phạm vi dữ liệu

Bộ dữ liệu được sử dụng là IBM Telco Customer Churn, một benchmark chuẩn trong lĩnh vực phân tích churn, được công bố công khai trên nền tảng Kaggle và IBM Developer. Bộ dữ liệu bao gồm:

Đặc điểm	Chi tiết
Số lượng mẫu	7.043 hồ sơ khách hàng (sau làm sạch: 7.032)
Số thuộc tính	21 thuộc tính (20 features + 1 biến mục tiêu Churn)
Tỷ lệ churn	26.5% (Yes) / 73.5% (No) — dữ liệu mất cân bằng
Biến số (numeric)	tenure, MonthlyCharges, TotalCharges
Biến phân loại	gender, SeniorCitizen, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies, Contract, PaperlessBilling, PaymentMethod

Phạm vi phân tích giới hạn ở việc xây dựng mô hình phân loại nhị phân và rút ra insight kinh doanh, không bao gồm triển khai hệ thống thời gian thực.

1.4. Bố cục của đề tài

Ngoài phần lời mở đầu, kết luận và danh mục tài liệu tham khảo, nội dung chính của báo cáo được kết cấu thành bốn chương như sau:

1. Chương 1: Tổng quan về báo cáo – trình bày bối cảnh bài toán, mô tả bộ dữ liệu, hệ thống thư viện, các thuật toán sẽ áp dụng và các chỉ số đánh giá.
2. Chương 2: Khám phá và phân tích dữ liệu – thực hiện EDA toàn diện, trực quan hóa phân bố dữ liệu và tìm kiếm mối quan hệ giữa các đặc trưng với biến mục tiêu.
3. Chương 3: Tiền xử lý dữ liệu – xây dựng pipeline làm sạch, biến đổi và chuẩn bị dữ liệu đầu vào cho giai đoạn huấn luyện mô hình.
4. Chương 4: Xây dựng mô hình học máy – huấn luyện, tinh chỉnh, so sánh các mô hình và đề xuất phương án can thiệp kinh doanh.

CHƯƠNG 1. TỔNG QUAN VỀ BÁO CÁO

1.1. Tổng quan về bài toán dự đoán khách hàng rời bỏ

Churn hay còn gọi là tình trạng rời bỏ khách hàng là thuật ngữ dùng để chỉ hiện tượng khách hàng ngừng sử dụng sản phẩm hoặc dịch vụ của một doanh nghiệp trong một khoảng thời gian nhất định. Trong ngành viễn thông, churn biểu hiện thông qua việc khách hàng chuyển sang nhà cung cấp khác, hủy hợp đồng hoặc đơn giản là không gia hạn sau khi hết thời hạn. Đây là một trong những vấn đề có tác động kinh tế lớn nhất mà các công ty viễn thông phải đối mặt, bởi lẽ ngành này có đặc thù là chi phí chuyển đổi ngày càng thấp do sự cạnh tranh về giá và dịch vụ ngày càng gia tăng.

Từ góc độ học máy, bài toán dự đoán churn được định nghĩa là một bài toán phân loại nhị phân: mỗi khách hàng được gán nhãn "sẽ rời bỏ" Churn = Yes hoặc "sẽ tiếp tục" Churn = No dựa trên tập hợp các đặc trưng mô tả hành vi và hợp đồng của họ. Mục tiêu của mô hình không phải là đạt độ chính xác cao nhất trên tổng thể, mà là tối đa hóa khả năng phát hiện đúng những khách hàng có nguy cơ rời bỏ tức là tối ưu hóa chỉ số Recall cho lớp churn. Điều này xuất phát từ bản chất bất cân xứng của hậu quả: bỏ sót một khách hàng sắp rời đi mang lại thiệt hại lớn hơn nhiều so với việc cảnh báo nhầm một khách hàng trung thành.

Đặc điểm đáng chú ý nhất của bài toán này là sự mất cân bằng lớp: trong thực tế, tỷ lệ khách hàng rời bỏ thường chỉ chiếm từ 15% đến 30% tổng số khách hàng. Sự mất cân bằng này buộc người xây dựng mô hình phải áp dụng các kỹ thuật đặc biệt như lấy mẫu lại, điều chỉnh trọng số lớp hoặc sử dụng các hàm mục tiêu phù hợp, thay vì chỉ đơn giản tối ưu hóa accuracy.

1.2. Tổng quan về bộ dữ liệu Telco Customer Churn

Bộ dữ liệu sử dụng trong đề tài là *Telco-Customer-Churn.csv*, được công bố công khai trên nền tảng Kaggle và là một trong những bộ dữ liệu chuẩn được sử dụng rộng rãi nhất trong các nghiên cứu về phân tích churn. Dữ liệu mô phỏng thông tin khách hàng của một công ty viễn thông giả định tại Hoa Kỳ, bao gồm 7.043 bản ghi và 21 cột đặc trưng thuộc nhiều nhóm khác nhau.

Bộ dữ liệu có thể được phân chia thành bốn nhóm đặc trưng chính.

Thứ nhất, nhóm thông tin nhân khẩu học bao gồm giới tính (gender), trạng thái người cao tuổi (SeniorCitizen), tình trạng hôn nhân (Partner) và tình trạng có người phụ thuộc (Dependents).

Thứ hai, nhóm thông tin hợp đồng và thanh toán gồm thời gian gắn bó (tenure tính bằng tháng), loại hợp đồng (Contract: hàng tháng, một năm hoặc hai năm), phương thức thanh toán (PaymentMethod), hóa đơn điện tử (PaperlessBilling), phí hàng tháng (MonthlyCharges) và tổng phí tích lũy (TotalCharges).

Thứ ba, nhóm dịch vụ điện thoại bao gồm dịch vụ điện thoại (PhoneService) và nhiều đường dây (MultipleLines).

Cuối cùng, nhóm dịch vụ Internet gồm loại dịch vụ Internet (InternetService: DSL, Fiber optic hoặc không có) kèm theo sáu dịch vụ đi kèm như OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV và StreamingMovies. Biến mục tiêu là cột Churn nhận giá trị Yes hoặc No.

Bảng 1. 1: Mô tả các cột trong bộ dữ liệu Telco Customer Churn

Tên cột	Kiểu dữ liệu	Mô tả
customerID	object	Mã định danh duy nhất của mỗi khách hàng
gender	object	Giới tính khách hàng
SeniorCitizen	int64	Người cao tuổi (1) hay không (0)
Partner / Dependents	object	Có người bạn đời / người phụ thuộc không
tenure	int64	Số tháng đã sử dụng dịch vụ
PhoneService / MultipleLines	object	Đăng ký dịch vụ điện thoại / nhiều đường
InternetService	object	Loại dịch vụ Internet (DSL/Fiber optic/No)

OnlineSecurity, OnlineBackup, DeviceProtection, TechSupport, StreamingTV, StreamingMovies	object	Các dịch vụ đi kèm Internet
Contract	object	Loại hợp đồng (Month-to-month/One year/Two year)
PaperlessBilling / PaymentMethod	object	Hóa đơn điện tử / Phương thức thanh toán
MonthlyCharges	float64	Phí dịch vụ hàng tháng (USD)
TotalCharges	object→float64	Tổng phí tích lũy
Churn	object	Nhân mục tiêu: khách hàng rời bỏ (Yes/No)

1.3. Hệ thống thư viện phân tích và học máy

Toàn bộ quy trình phân tích và xây dựng mô hình trong đề tài được thực hiện trên nền tảng Python 3, chạy trong môi trường Google Colab. Bộ thư viện được sử dụng bao gồm:

Pandas và NumPy: Là hai thư viện xương sống cho việc xử lý dữ liệu dạng bảng. Pandas cung cấp cấu trúc DataFrame linh hoạt cho phép đọc, lọc, nhóm và biến đổi dữ liệu một cách hiệu quả. NumPy hỗ trợ các phép toán số học và ma trận tốc độ cao, làm nền tảng tính toán cho hầu hết các thư viện khoa học dữ liệu khác.

Matplotlib và Seaborn: Được sử dụng để trực quan hóa dữ liệu trong giai đoạn EDA. Seaborn cung cấp các hàm vẽ cấp cao với giao diện đẹp mặc định, trong khi Matplotlib cho phép tùy chỉnh chi tiết từng thành phần của biểu đồ.

Scikit-learn: Thư viện học máy trung tâm của đề tài, cung cấp đầy đủ công cụ cho toàn bộ vòng đời của mô hình: tiền xử lý (StandardScaler, MinMaxScaler, LabelEncoder, get_dummies), chia dữ liệu (train_test_split), huấn luyện mô hình

(KNeighborsClassifier, LogisticRegression, SVC, RandomForestClassifier), điều chỉnh siêu tham số (GridSearchCV) và đánh giá (classification_report, roc_auc_score, confusion_matrix).

1.4. Các mô hình học máy được áp dụng

Đề tài áp dụng bốn thuật toán học máy có giám sát cho bài toán phân loại nhị phân: K-Nearest Neighbors (KNN), Logistic Regression, Support Vector Machine (SVM) và Random Forest. Mỗi mô hình được trình bày đầy đủ về nguyên lý toán học, đặc điểm kỹ thuật và lý do lựa chọn trong ngữ cảnh bài toán dự đoán churn.

K-Nearest Neighbors: KNN là phương pháp học lười dựa trên khoảng cách. Mô hình không xây dựng hàm quyết định tường minh trong giai đoạn huấn luyện thay vào đó, toàn bộ tập huấn luyện được lưu lại và chỉ sử dụng khi cần dự đoán.

Khi nhận một điểm dữ liệu mới x , KNN thực hiện ba bước:

- Tính khoảng cách từ x đến tất cả điểm trong tập train
- Chọn K điểm gần nhất (K-nearest neighbors)
- Gán nhãn theo bỏ phiếu đa số trong K hàng xóm đó.

Công thức khoảng cách Euclidean: Khoảng cách giữa điểm cần dự đoán x và điểm huấn luyện x_i được tính theo:

$$d(x, x_i) = \sqrt{[\sum_j (x_j - x_{ij})^2]} \quad (\text{khoảng cách Euclidean})$$

Trong đó:

x : điểm cần dự đoán

x_i : điểm thứ i trong tập huấn luyện

x_j, x_{ij} : giá trị của đặc trưng thứ j

$\sum_j$: tổng trên tất cả các chiều đặc trưng

Tham số K ảnh hưởng trực tiếp đến bias-variance tradeoff: K nhỏ gây overfitting, K lớn gây underfitting. KNN không giả định phân phối dữ liệu và có thể mô hình hóa ranh giới quyết định phi tuyến phức tạp. Nhược điểm chính là độ phức tạp tính toán $O(nd)$ tại thời điểm dự đoán và nhạy cảm với dữ liệu nhiễu sau khi One-Hot Encoding. Trong bài toán này, KNN yêu cầu chuẩn hóa dữ liệu bắt buộc để các đặc trưng có đơn vị khác nhau không chi phối khoảng cách.

Logistic Regression: Là mô hình tuyến tính cổ điển cho bài toán phân loại nhị phân. Quá trình tính toán gồm hai bước:

Bước 1: Tổ hợp tuyến tính

Tính giá trị kết hợp tuyến tính của tất cả đặc trưng:

$$Z = w_0 + w_1x_1 + w_2x_2 + \dots + w_nx_n \quad (\text{linear combination})$$

Trong đó:

w_0 : hệ số chặn (intercept / bias)

$w_1 \dots w_n$: trọng số (weights) của từng đặc trưng

$x_1 \dots x_n$: giá trị các đặc trưng của mẫu cần dự đoán

Bước 2 Hàm Sigmoid

Áp dụng hàm sigmoid để ép đầu ra về khoảng xác suất $[0, 1]$:

$$\sigma(z) = 1 / (1 + e^{-z}) \quad (\text{sigmoid function})$$

Kết quả $\sigma(z)$ được hiểu là xác suất khách hàng rời bỏ. Nếu $\sigma(z) > 0.5 \rightarrow$ dự đoán Churn = Yes.

Đây là ưu điểm lớn nhất của Logistic Regression khả năng giải thích trực tiếp từ hệ số w_i :

- $w_i > 0$: Khi x_i tăng $\rightarrow$ xác suất churn tăng
- $w_i < 0$: Khi x_i tăng $\rightarrow$ xác suất churn giảm
- $|w_i|$ lớn: Đặc trưng x_i có ảnh hưởng mạnh đến quyết định rời bỏ

Trong bài toán mất cân bằng lớp, Logistic Regression cho phép sử dụng tham số `class_weight='balanced'` để điều chỉnh trọng số, giúp mô hình không thiên vị về lớp đa số. Mô hình này thường là baseline đầu tiên trong các bài toán churn prediction do tính ổn định và tốc độ huấn luyện nhanh.

Support Vector Machine – SVM: Là thuật toán tìm kiếm siêu phẳng tối ưu phân tách hai lớp với biên lớn nhất. Trong không gian tuyến tính, SVM giải bài toán tối ưu: tối đa hóa $2/\|w\|$ với điều kiện $y_i(w^T x_i + b) \geq 1$ với mọi điểm dữ liệu i . Các điểm nằm trên biên được gọi là support vectors chúng là những điểm duy nhất quyết định vị trí của siêu phẳng. Với dữ liệu không phân tách tuyến tính, SVM sử dụng kernel trick để ánh xạ dữ liệu lên không gian chiều cao hơn mà không cần tính tường minh phép biến đổi. Kernel RBF $K(x, x') = \exp(-\gamma \|x - x'\|^2)$ là lựa chọn phổ biến vì có khả năng mô hình hóa ranh giới quyết định phi tuyến phức tạp. Tham số C kiểm soát cân bằng giữa tối đa hóa biên

và sai số phân loại: C nhỏ thì biên rộng hơn nhưng cho phép nhiều lỗi hơn, C lớn thì biên hẹp nhưng ít lỗi trên tập train hơn.

Random Forest: Là phương pháp học tổ hợp dựa trên kỹ thuật Bagging. Thay vì xây dựng một cây quyết định duy nhất, mô hình xây dựng T cây độc lập và tổng hợp kết quả.

Mỗi cây trong rừng được xây dựng theo quy trình ngẫu nhiên hai tầng:

- Ngẫu nhiên theo mẫu: Lấy mẫu bootstrap (lấy có hoàn lại) từ tập train để tạo tập con huấn luyện cho mỗi cây
- Ngẫu nhiên theo đặc trưng: Tại mỗi nút phân nhánh, chỉ xét một tập con ngẫu nhiên gồm $\sqrt{p}$ đặc trưng thay vì toàn bộ

Số đặc trưng xét tại mỗi nút = $\sqrt{p}$ (p là tổng số đặc trưng)

Kết quả cuối cùng được tổng hợp bằng bỏ phiếu đa số trên toàn bộ T cây. Cơ chế đa dạng hóa này giúp Random Forest kháng overfitting tốt hơn cây quyết định đơn lẻ vì sai số tổng hợp phụ thuộc vào tương quan giữa các cây, không phải sai số từng cây. Một ưu điểm quan trọng của Random Forest là khả năng tính Feature Importance dựa trên mức giảm impurity trung bình khi mỗi đặc trưng được dùng để phân nhánh, cung cấp insight kinh doanh trực tiếp từ kết quả mô hình.

1.5. Các chỉ số đánh giá hiệu năng mô hình

Việc chọn đúng chỉ số đánh giá đóng vai trò then chốt trong một bài toán có dữ liệu mất cân bằng như churn prediction. Đề tài sử dụng bộ chỉ số đánh giá đa chiều như sau:

Accuracy: Tỷ lệ dự đoán đúng trên tổng số mẫu. Đây là chỉ số phổ biến nhất nhưng lại gây hiểu lầm trong bài toán mất cân bằng – một mô hình luôn dự đoán "No churn" cũng đạt accuracy 73,5% mà không có bất kỳ giá trị thực tiễn nào.

Precision: Trong số các khách hàng được dự đoán là sẽ rời bỏ, bao nhiêu phần trăm thực sự rời bỏ. Precision cao giúp giảm lãng phí trong các chiến dịch chăm sóc khách hàng.

Recall: Trong số các khách hàng thực sự rời bỏ, bao nhiêu phần trăm được mô hình phát hiện ra. Đây là chỉ số quan trọng nhất trong bài toán churn vì bỏ sót khách hàng nguy cơ cao là hậu quả tồi tệ nhất.

F1-Score: Trung bình điều hòa giữa Precision và Recall, cân bằng hai chỉ số trên thành một con số duy nhất. F1 đặc biệt hữu ích khi cân so sánh tổng thể giữa các mô hình.

ROC-AUC (Area Under the ROC Curve): Đo lường khả năng phân biệt giữa hai lớp của mô hình ở tất cả các ngưỡng phân loại. $AUC = 1.0$ là mô hình hoàn hảo, $AUC = 0.5$ tương đương đoán ngẫu nhiên. Đây là chỉ số không phụ thuộc vào ngưỡng quyết định và phản ánh khả năng phân biệt thực sự của mô hình tốt nhất.

Với các đặc thù của bài toán, ta nên ưu tiên tối ưu hóa Recall và AUC thay vì chỉ nhìn vào Accuracy khi so sánh và lựa chọn mô hình tốt nhất.

CHƯƠNG 2: KHÁM PHÁ VÀ PHÂN TÍCH DỮ LIỆU

2.1. Đọc và mô tả ban đầu về dữ liệu

Bộ dữ liệu được nạp bằng hàm `pd.read_csv()` của thư viện Pandas và xác nhận có kích thước (7043, 21) – tức 7.043 bản ghi khách hàng và 21 thuộc tính. Việc kiểm tra sơ bộ bằng `df.head()` và `df.info()` cho thấy toàn bộ dữ liệu có 7.043 giá trị non-null ở hầu hết các cột, với một ngoại lệ đáng chú ý tại cột `TotalCharges`: mặc dù được ghi nhận là non-null theo pandas, nhưng thực chất chứa 11 dòng có giá trị là chuỗi khoảng trắng " " thay vì số thực, khiến cột này bị nhận dạng sai kiểu dữ liệu là `object` thay vì `float64`.

Đây là một ví dụ điển hình của dữ liệu bản không có giá trị null thực sự theo định nghĩa kỹ thuật, nhưng lại chứa giá trị không hợp lệ về mặt ngữ nghĩa. Những trường hợp này nếu không được phát hiện và xử lý sẽ gây ra lỗi trong giai đoạn tính toán số học hoặc làm lệch kết quả phân tích. Phân tích thêm cho thấy 11 dòng này đều có thuộc tính `tenure = 0`, nghĩa là đây là các khách hàng mới đăng ký nhưng chưa phát sinh hóa đơn, do đó `TotalCharges` của họ về bản chất là chưa xác định.

2.2. Kiểm tra cấu trúc và chất lượng dữ liệu

Kết quả kiểm tra bằng `data.isna().sum()` xác nhận không có giá trị null thực sự ở bất kỳ cột nào. Kết quả kiểm tra bằng `data.duplicated().sum()` cho thấy không có dòng trùng lặp trong dữ liệu. Tuy nhiên, như đã phân tích, 11 giá trị " " trong cột `TotalCharges` là vấn đề cần xử lý trước khi tiến hành bất kỳ phân tích số học nào.


Bảng 2. 1: Thống kê số lượng giá trị thiếu và không hợp lệ theo từng cột

Loại vấn đề	Cột bị ảnh hưởng	Số lượng
Giá trị null (NaN)	Không có cột nào	0
Chuỗi khoảng trắng " "	TotalCharges	11
Dòng trùng lặp	Toàn bộ bảng	0
Kiểu dữ liệu sai (object thay vì float)	TotalCharges	Toàn cột

2.3. Phân bố biến mục tiêu Churn

Bước đầu tiên và quan trọng nhất trong phân tích biến mục tiêu là xác định mức độ mất cân bằng giữa các lớp, bởi vì điều này ảnh hưởng trực tiếp đến chiến lược chọn mô hình và phương pháp đánh giá sau này. Kết quả đếm giá trị cho thấy trong tổng số 7.043 khách hàng, có 5.174 khách hàng được gán nhãn "Không churn" (No) và 1.869 khách hàng được gán nhãn "Churn" (Yes), tương ứng với tỷ lệ 73,5% và 26,5%.

Tỷ lệ churn 26,5% cho thấy dữ liệu bị mất cân bằng ở mức trung bình không quá nghiêm trọng như các bài toán phát hiện gian lận (thường dưới 1%), nhưng đủ để gây ra hiện tượng thiên kiến lớp đa số trong các mô hình học máy nếu không có biện pháp xử lý phù hợp. Một mô hình ngây thơ luôn dự đoán "Không churn" có thể đạt accuracy tới 73,5% mà không hề mang lại bất kỳ giá trị kinh doanh nào. Điều này khẳng định rằng accuracy không phải là chỉ số đánh giá phù hợp, và nhóm cần tập trung vào Recall và ROC-AUC như đã đề cập ở Chương 1.



Biểu đồ 2. 1: Phân bố số lượng và tỷ lệ khách hàng theo nhãn Churn

2.4. Phân tích biến phân loại theo Churn

Để trả lời câu hỏi "nhóm khách hàng nào có tỷ lệ rời bỏ cao hơn", trực quan hóa phân bố của 15 biến phân loại theo biến mục tiêu Churn bằng các biểu đồ cột nhóm. Một số phát hiện quan trọng có thể rút ra như sau.

Loại hợp đồng (Contract) là yếu tố có ảnh hưởng rõ rệt nhất. Khách hàng ký hợp đồng theo tháng (Month-to-month) có tỷ lệ churn vượt trội so với khách hàng ký hợp đồng một năm hoặc hai năm. Điều này hoàn toàn hợp lý về mặt kinh tế: không bị ràng buộc dài hạn khiến chi phí chuyển đổi về phía khách hàng gần như bằng không.


Loại dịch vụ Internet (InternetService): Khách hàng sử dụng dịch vụ Fiber optic có tỷ lệ churn cao nhất trong ba nhóm, cao hơn đáng kể so với khách hàng dùng DSL hay

không có Internet. Kết hợp với phân tích biến số ở phần sau, điều này có liên quan mật thiết đến mức phí hàng tháng cao hơn của dịch vụ Fiber optic.

Các dịch vụ bổ sung (OnlineSecurity, TechSupport, OnlineBackup): Khách hàng không đăng ký các dịch vụ bổ sung như bảo mật trực tuyến hay hỗ trợ kỹ thuật có tỷ lệ churn cao hơn đáng kể so với khách hàng có đăng ký. Phát hiện này gợi ý rằng việc khuyến khích khách hàng sử dụng thêm các dịch vụ đi kèm không chỉ tăng doanh thu mà còn có tác dụng "neo" khách hàng lại với nhà cung cấp.

Phương thức thanh toán (PaymentMethod): Khách hàng sử dụng hình thức thanh toán bằng séc điện tử (Electronic check) có tỷ lệ churn cao nhất trong các phương thức thanh toán, trong khi thanh toán tự động (Credit card automatic hoặc Bank transfer automatic) có tỷ lệ churn thấp hơn hẳn. Khách hàng thiết lập thanh toán tự động thể hiện mức độ cam kết cao hơn và ít có khả năng rời bỏ.

Nhóm thời gian gắn bó (Tenure_Group): Khách hàng trong nhóm 0–1 năm có tỷ lệ churn áp đảo so với các nhóm còn lại, xác nhận rằng giai đoạn đầu tiên sau khi đăng ký dịch vụ là thời điểm nhạy cảm nhất và cần được ưu tiên chăm sóc.



Biểu đồ 2. 2: Biểu đồ Churn theo từng biến phân loại (18 biểu đồ nhóm)

Tổng thể, kết quả EDA cho thấy churn có liên hệ nổi bật với các biến phản ánh mức độ cam kết của khách hàng (Contract, Tenure_Group), trải nghiệm và cấu hình dịch vụ (InternetService), cũng như mức độ sử dụng các dịch vụ giá trị gia tăng (OnlineSecurity, TechSupport, DeviceProtection). Bên cạnh đó, một số biến hành vi giao dịch như PaymentMethod và PaperlessBilling cũng thể hiện khả năng phân tách nhất định giữa hai nhóm khách hàng. Ngược lại, biến Gender cho thấy giá trị giải thích thấp.

Từ góc độ xây dựng mô hình, các biến có tín hiệu rõ rệt nên được ưu tiên xem xét trong bước chọn đặc trưng. Từ góc độ quản trị, doanh nghiệp có thể tập trung vào nhóm khách hàng mới, khách hàng sử dụng hợp đồng ngắn hạn và khách hàng chưa đăng ký dịch vụ hỗ trợ để thiết kế các chính sách giữ chân phù hợp. Tuy nhiên, cần nhấn mạnh rằng các nhận xét ở giai đoạn EDA chủ yếu mang tính mô tả; việc khẳng định mức độ tác động của từng biến cần tiếp tục được kiểm định bằng các phương pháp thống kê hoặc mô hình học máy ở các bước nghiên cứu tiếp theo.


2.5. Phân tích biến số theo Churn

Để phân tích ba biến số liên tục *tenure*, *MonthlyCharges* và *TotalCharges* theo nhóm Churn, nhóm sử dụng biểu đồ *boxplot* nhằm so sánh phân phối của từng biến giữa hai nhóm khách hàng. Kết quả mang lại ba phát hiện có giá trị cao.

Đối với biến *tenure*: Khách hàng thuộc nhóm churn có trung vị *tenure* thấp hơn rõ rệt so với nhóm không churn. Điều này xác nhận quan sát từ phân tích biến phân loại: khách hàng mới có nguy cơ rời bỏ cao hơn đáng kể. Điều này gợi ý rằng doanh nghiệp cần đặc biệt chú trọng giai đoạn "onboarding" sáu tháng đầu tiên sau khi khách hàng đăng ký dịch vụ với các chương trình chăm sóc tích cực.

Đối với biến *MonthlyCharges*: Nhóm khách hàng churn có phí hàng tháng trung bình cao hơn nhóm không churn. Đây là một mối quan hệ nghịch lý bề ngoài nhưng có thể giải thích được: những khách hàng trả phí cao hơn thường là người dùng dịch vụ Fiber optic hoặc đăng ký nhiều dịch vụ bổ sung nhưng lại không cảm thấy giá trị tương xứng với chi phí bỏ ra, dẫn đến quyết định rời bỏ.

Đối với biến *TotalCharges*: Ngược lại với *MonthlyCharges*, nhóm churn có tổng phí tích lũy thấp hơn so với nhóm không churn. Đây là hệ quả tự nhiên của việc khách hàng rời đi sớm dù phí hàng tháng cao, thời gian sử dụng ngắn khiến tổng phí tích lũy không thể cao bằng khách hàng đã gắn bó nhiều năm.




Biểu đồ 2. 3: Boxplot phân bố biến số tenure, MonthlyCharges và TotalCharges theo Churn

2.6. Phân tích chi phí trung bình theo nhóm thời gian gắn bó

Để có cái nhìn đa chiều hơn về mối quan hệ giữa thời gian gắn bó và hành vi chi tiêu, nhóm xây dựng biểu đồ so sánh chi phí trung bình (MonthlyCharges và TotalCharges) theo từng nhóm tenure, phân tách theo nhãn Churn. Phân tích này dẫn đến một phát hiện mang tính tổng hợp quan trọng:

Ở tất cả sáu nhóm tenure từ 0–1 năm đến 5–6 năm, khách hàng churn đều có MonthlyCharges trung bình cao hơn khách hàng không churn. Đây là một quy luật nhất quán, không phụ thuộc vào thời gian gắn bó. Điều này phủ định khả năng yếu tố "thời gian" là nguyên nhân duy nhất, và cho thấy mức phí hàng tháng cao là một yếu tố rủi ro độc lập.

Riêng với nhóm 0–1 năm: TotalCharges của nhóm churn thấp hơn rất nhiều so với nhóm không churn trong cùng nhóm tenure, bởi lẽ họ rời đi quá sớm trước khi tích lũy đủ chi phí. Kết hợp với MonthlyCharges cao, đây là bằng chứng rõ ràng rằng "*phí cao kết hợp với tenure thấp là tín hiệu rủi ro churn mạnh nhất*" một insight trực tiếp có thể ứng dụng vào hệ thống cảnh báo sớm trong kinh doanh.



Biểu đồ 2. 4: Biểu đồ chi phí trung bình theo nhóm Tenure_Group và nhãn Churn

Tóm lại, giai đoạn EDA đã mang lại ba nhóm phát hiện chính có giá trị cao cho giai đoạn xây dựng mô hình: (1) Loại hợp đồng, loại dịch vụ Internet và thời gian gắn bó là các biến phân loại có sức phân biệt lớn nhất; (2) phí hàng tháng cao và tenure ngắn là tổ hợp đặc trưng nguy cơ mạnh nhất; (3) dữ liệu bị mất cân bằng ở mức đáng kể, đòi hỏi các giải pháp kỹ thuật phù hợp trong giai đoạn tiền xử lý và đánh giá mô hình

CHƯƠNG 3. TIỀN XỬ LÝ DỮ LIỆU

Tiền xử lý dữ liệu là cầu nối giữa dữ liệu thô từ giai đoạn EDA và dữ liệu sẵn sàng để đưa vào mô hình học máy. Chương này trình bày chi tiết từng bước trong pipeline tiền xử lý được xây dựng theo đúng thứ tự logic, đảm bảo không xảy ra data leakage và kết quả đánh giá mô hình phản ánh hiệu năng thực tế.

3.1. Xử lý dữ liệu thiếu và không hợp lệ

Như đã phát hiện trong EDA, vấn đề dữ liệu duy nhất cần xử lý là 11 dòng trong cột TotalCharges chứa chuỗi khoảng trắng " ". Các dòng này tương ứng với khách hàng có tenure = 0, tức chưa phát sinh hóa đơn. Quy trình xử lý gồm hai bước tuần tự: đầu tiên dùng `pd.to_numeric(errors="coerce")` để ép kiểu cột TotalCharges sang số, các chuỗi không hợp lệ sẽ tự động trở thành NaN; tiếp theo xóa các dòng NaN bằng `data.dropna()`. Song song đó, cột customerID cũng được loại bỏ vì là mã định danh không mang thông tin dự đoán.

Quyết định xóa 11 dòng này thay vì thay thế bằng giá trị ước tính là hoàn toàn hợp lý vì ba lý do. Một là, 11 dòng chỉ chiếm 0,16% tổng dữ liệu quá nhỏ để ảnh hưởng đến phân bố tổng thể. Hai là, giá trị TotalCharges của nhóm này về bản chất là chưa xác định, nên không thể impute một cách có ý nghĩa từ phân bố của các khách hàng đã có hóa đơn. Ba là, việc giữ lại và impute sẽ đưa ra một giá trị không thực tế, có thể làm nhiễu tín hiệu của biến TotalCharges trong mô hình. Sau bước này, tập dữ liệu còn lại 7.032 dòng với đầy đủ giá trị hợp lệ.

3.2. Chia tập huấn luyện và kiểm tra

Dữ liệu được chia thành tập huấn luyện (80%) và tập kiểm tra (20%) bằng hàm `train_test_split()` với hai tham số quan trọng: `test_size=0.2`, `random_state=42` và `stratify=y`. Tham số `stratify` đảm bảo tỷ lệ churn được giữ nguyên trong cả hai tập, tránh tình trạng phân bố lớp lệch giữa train và test.

Kết quả chia tập: `X_train` gồm 5.625 dòng và `X_test` gồm 1.407 dòng, đều duy trì tỷ lệ churn 26,5% như tập gốc. Đây là nguyên tắc không thể bỏ qua trong bài toán mất cân bằng lớp: nếu không `stratify`, tập test có thể vô tình chứa quá ít mẫu churn, dẫn đến đánh giá mô hình không đại diện cho điều kiện triển khai thực tế.

Một nguyên tắc kỹ thuật quan trọng được tuân thủ xuyên suốt: mọi bước tiền xử lý `encoding`, `scaling` đều được fit chỉ trên tập train, sau đó transform riêng rẽ lên tập test.

Vì phạm nguyên tắc này sẽ dẫn đến data leakage thông tin từ tập test "rò rỉ" vào quá trình huấn luyện, làm cho kết quả đánh giá lạc quan hơn thực tế.

3.3. Mã hóa biến phân loại (One-Hot Encoding)

Tất cả các cột có kiểu object trong `X_train` được xác định tự động và mã hóa bằng `pd.get_dummies(drop_first=True)`. Tham số `drop_first=True` loại bỏ một cột dummy trong mỗi nhóm để tránh hiện tượng đa cộng tuyến hoàn hảo. Sau đó, `X_test` được căn chỉnh theo đúng cấu trúc cột của `X_train` bằng `X_train.align(X_test, join="left", fill_value=0)` để đảm bảo hai tập có số lượng cột giống nhau.

Sau bước mã hóa, dữ liệu mở rộng từ 19 cột ban đầu sau khi loại `customerID` và `Churn` lên khoảng 30 cột đặc trưng số, không còn cột nào có kiểu dữ liệu object.

3.4. Chuẩn hóa dữ liệu (StandardScaler)

Tất cả đặc trưng số được chuẩn hóa bằng `StandardScaler`: fit trên `X_train` để tính mean và std, sau đó transform cả `X_train` và `X_test`. Kết quả là `X_train_sc` và `X_test_sc` dữ liệu đã được đưa về phân phối chuẩn với mean ≈ 0 và std ≈ 1 cho mỗi đặc trưng.

Bước chuẩn hóa đặc biệt quan trọng với SVM và Logistic Regression vốn nhạy cảm với chênh lệch thang đo giữa các đặc trưng ví dụ: `tenure` chỉ từ 0–72 trong khi `TotalCharges` có thể đến hàng nghìn. Random Forest ít bị ảnh hưởng bởi scale nhưng chuẩn hóa đồng nhất vẫn giúp `GridSearchCV` so sánh công bằng hơn.

3.5. Chiến lược tiền xử lý toàn diện

Bảng dưới đây tóm tắt toàn bộ pipeline tiền xử lý theo thứ tự thực hiện:

Bảng 3. 1: Chiến lược tiền xử lý dữ liệu theo từng bước

Bước	Thao tác	Mô tả chi tiết
1	Làm sạch <code>TotalCharges</code>	<code>pd.to_numeric(errors='coerce') + dropna()</code> — xóa 11 dòng không hợp lệ, ép kiểu sang <code>float64</code> .
2	Loại bỏ <code>customerID</code>	Xóa cột mã định danh không mang thông tin dự đoán.
3	Tách nhãn & chia train/test	Tách <code>y = Churn.map({'No':0,'Yes':1})</code> . Chia 80/20, <code>stratify=y</code> , <code>random_state=42</code> .

4	One-Hot Encoding	pd.get_dummies(drop_first=True) trên cat_cols của X_train. Căn chỉnh X_test theo cột X_train.
5	Chuẩn hóa (StandardScaler)	fit trên X_train, transform X_train và X_test → X_train_sc, X_test_sc.

Sau khi hoàn thành toàn bộ năm bước, dữ liệu sẵn sàng đưa vào các mô hình học máy: X_train_sc (5.625 mẫu) và X_test_sc (1.407 mẫu), mỗi mẫu có khoảng 30 đặc trưng số, không có giá trị thiếu và đã được chuẩn hóa đồng nhất.

CHƯƠNG 4: XÂY DỰNG MÔ HÌNH HỌC MÁY

Sau khi hoàn thành giai đoạn tiền xử lý và có trong tay dữ liệu sạch, chuẩn hóa đầy đủ, chương này trình bày quy trình xây dựng, huấn luyện và đánh giá bốn mô hình học máy theo một pipeline thống nhất: tối ưu hóa siêu tham số bằng GridSearchCV, so sánh toàn diện các mô hình, lựa chọn mô hình tốt nhất, phân tích Feature Importance và rút ra insight kinh doanh.

4.1. Thiết kế bài toán và lựa chọn thuật toán

Bài toán được xác định là phân loại nhị phân có giám sát: từ tập 30 đặc trưng sau tiền xử lý, mô hình cần dự đoán xác suất khách hàng thuộc lớp churn ($Churn = 1$). Ngưỡng phân loại mặc định 0,5 có thể điều chỉnh tùy theo yêu cầu kinh doanh muốn tăng độ nhạy Recall có thể hạ xuống 0,3 hoặc 0,4.

Bốn thuật toán được lựa chọn từ các họ cơ chế khác nhau để đảm bảo tính đa dạng trong so sánh:

Bảng 4. 1: Các mô hình học máy được lựa chọn và lý do

Mô hình	Lý do lựa chọn
Logistic Regression	Baseline tuyến tính, dễ giải thích, hiệu quả khi dữ liệu đã chuẩn hóa
KNN	Không giả định phân phối, phù hợp khám phá đặc điểm cục bộ
SVM	Mạnh với biên phi tuyến, hiệu quả trong không gian nhiều chiều
Random Forest	Ensemble mạnh, kháng overfitting, cung cấp feature importance

Toàn bộ quá trình huấn luyện và tối ưu siêu tham số được thực hiện hoàn toàn trên tập train. Tập test chỉ được dùng một lần duy nhất để đánh giá mô hình cuối cùng, tuyệt đối không tham gia vào bất kỳ bước nào của quá trình huấn luyện.

4.2. Tối ưu hóa siêu tham số bằng GridSearchCV

Tất cả bốn mô hình đều được tối ưu hóa đồng thời bằng GridSearchCV với StratifiedKFold ($k=5$) và metric tối ưu hóa là recall. Lựa chọn recall làm scoring nhằm ưu tiên phát hiện đúng khách hàng churn giảm thiểu False Negative vì chi phí bỏ sót một khách sắp rời đi lớn hơn nhiều so với chi phí tiếp cận nhầm một khách trung thành.

Không gian tham số được thiết kế có chủ đích cho từng thuật toán:


Bảng 4. 2: Không gian tìm kiếm siêu tham số cho từng mô hình

Mô hình	Siêu tham số tìm kiếm
Logistic Regression	$C \in \{0.1, 1, 10\}$; $\text{solver} \in \{\text{lbfgs}, \text{liblinear}\}$; $\text{class_weight} = \text{balanced}$
KNN	$n_neighbors \in \{3, 5, 9\}$; $\text{weights} \in \{\text{uniform}, \text{distance}\}$
SVM	$C \in \{0.1, 1, 10\}$; $\text{kernel} \in \{\text{rbf}, \text{linear}\}$; $\text{class_weight} = \text{balanced}$
Random Forest	$n_estimators \in \{100, 200\}$; $\text{max_depth} \in \{5, \text{None}\}$; $\text{min_samples_split} \in \{2, 5, 10\}$; $\text{min_samples_leaf} \in \{1, 2\}$; $\text{max_features} = \text{sqrt}$; $\text{class_weight} = \text{balanced}$

Với Logistic Regression và SVM, tham số $\text{class_weight} = \text{'balanced'}$ được cố định nhằm xử lý mất cân bằng lớp ngay trong hàm mục tiêu. Với Random Forest, $\text{class_weight} = \text{'balanced'}$ kết hợp với điều chỉnh min_samples_split giúp kiểm soát đồng thời cả overfitting và bias về lớp thiểu số.

4.3. Kết quả đánh giá và so sánh mô hình

Sau khi GridSearchCV tìm được bộ siêu tham số tối ưu cho mỗi mô hình, kết quả đánh giá trên tập test được tổng hợp trong biểu đồ so sánh dưới đây.



Hình ảnh 4. 1: Báo cáo Đánh giá Mô hình Dự đoán

Mô hình Hồi quy Logistic đạt độ chính xác tổng thể là 72,6%, với giá trị Recall đối với lớp Churn ở mức 79,7% thuộc nhóm cao nhất trong số các mô hình được khảo sát. Điều này cho thấy mô hình có khả năng phát hiện một tỷ lệ lớn các trường hợp khách hàng có nguy cơ rời bỏ thực sự. Tuy nhiên, chỉ số Precision chỉ đạt 49,1%, phản ánh rằng gần một nửa số khách hàng được mô hình dự đoán là "Churn" trên thực tế không rời bỏ dịch vụ, dẫn đến tỷ lệ dương tính giả (false positive) cao. Giá trị F1-score ở mức

0,608 phản ánh sự mất cân đối giữa Precision và Recall nêu trên. Đường cong học tập cho thấy điểm số trên tập huấn luyện và tập kiểm định chéo hội tụ ổn định, không có dấu hiệu quá khớp overfitting, cho thấy mô hình có khả năng tổng quát hóa tốt.

Mô hình KNN ghi nhận độ chính xác tổng thể cao nhất trong nhóm với giá trị 76,5%. Tuy nhiên, con số này có thể gây hiểu lầm về hiệu suất thực sự của mô hình. Cụ thể, ba chỉ số Precision, Recall và F1 đối với lớp Churn đều chỉ dao động trong khoảng 0,553 đến 0,559 mức thấp nhất trong số bốn mô hình được phân tích. Điều này cho thấy mô hình KNN phân loại phần lớn các mẫu vào lớp chiếm đa số No Churn và không phân biệt hiệu quả khách hàng có nguy cơ rời bỏ. Đặc biệt đáng lưu ý, đường cong học tập của KNN thể hiện rõ hiện tượng quá khớp: điểm số trên tập huấn luyện duy trì ở mức cao ($\sim 0,84$) trong khi điểm số kiểm định chéo thấp hơn đáng kể ($\sim 0,75$) và không có xu hướng hội tụ. Căn cứ vào các phân tích trên, mô hình KNN không được khuyến nghị sử dụng cho bài toán này, bất chấp giá trị accuracy bề ngoài cao.

Mô hình SVM đạt độ chính xác tổng thể thấp nhất trong nhóm với giá trị 68,7%, song lại ghi nhận chỉ số Recall đối với lớp Churn cao nhất trong tất cả các mô hình được nghiên cứu, đạt 81,6%. Kết quả này cho thấy SVM có ưu thế vượt trội trong việc phát hiện khách hàng có nguy cơ rời bỏ, hạn chế tối đa khả năng bỏ sót các trường hợp thực sự thuộc lớp Churn (false negative thấp). Tuy nhiên, chỉ số Precision thấp ở mức 45,1% đồng nghĩa với việc phần lớn các dự đoán dương tính là không chính xác, tạo ra gánh nặng cho các chiến lược can thiệp giữ chân khách hàng nếu được triển khai trực tiếp. Đường cong học tập của SVM không cho thấy hiện tượng quá khớp, với hai đường biểu diễn hội tụ ổn định về cùng một ngưỡng. Mô hình SVM phù hợp trong bối cảnh mà chi phí bỏ sót một khách hàng rời bỏ cao hơn đáng kể so với chi phí can thiệp nhầm.

Mô hình Rừng ngẫu nhiên đạt sự cân bằng tốt nhất giữa các chỉ số hiệu suất, với độ chính xác tổng thể 73,0%, Recall đạt 79,9% và F1-score cao nhất trong nhóm ở mức 0,611. Phân phối dự đoán trên ma trận nhầm lẫn cho thấy mô hình phân loại hợp lý cả hai lớp, không có sự thiên lệch quá mức về phía một lớp đặc thù nào. Đường cong học tập thể hiện xu hướng điểm số trên tập huấn luyện giảm dần về phía điểm số kiểm định chéo khi kích thước mẫu tăng đây là đặc điểm của một mô hình có khả năng tổng quát hóa tốt, không bị quá khớp. Nhìn chung, Rừng ngẫu nhiên là lựa chọn ưu tiên khi mục tiêu là tối ưu hóa đồng thời cả khả năng phát hiện churn lẫn độ tin cậy của dự đoán.


Dựa trên kết quả phân tích tổng hợp, mô hình Rừng ngẫu nhiên được đánh giá là lựa chọn phù hợp nhất cho bài toán dự đoán khách hàng rời bỏ trong nghiên cứu này, nhờ sự cân bằng vượt trội giữa các chỉ số và tính ổn định trong quá trình học. Trong trường hợp yêu cầu ưu tiên tối đa hóa Recall tức là giảm thiểu mọi trường hợp bỏ sót khách hàng có nguy cơ rời bỏ mô hình SVM có thể được xem xét như một phương án thay thế. Ngược lại, mô hình KNN không được khuyến nghị do hiện tượng quá khớp rõ ràng, mặc dù đạt giá trị accuracy cao nhất về mặt số học. Các nghiên cứu tiếp theo có thể cân nhắc tối ưu hóa siêu tham số, áp dụng các kỹ thuật xử lý mất cân bằng lớp như SMOTE, hoặc khảo sát các mô hình ensemble nâng cao nhằm cải thiện thêm hiệu suất phân loại.

4.4. Lựa chọn mô hình tốt nhất

Random Forest được lựa chọn làm mô hình cuối cùng dựa trên bốn lý do chính. Thứ nhất, mô hình đạt Recall đối với nhóm khách hàng rời bỏ ở mức cao nhất (khoảng 0.80), phù hợp với mục tiêu ưu tiên phát hiện tối đa các trường hợp churn và giảm thiểu sai sót loại bỏ nhầm (False Negative). Thứ hai, giá trị AUC của mô hình xấp xỉ 0.84 ở mức cạnh tranh, cho thấy khả năng phân biệt hai lớp ổn định trên nhiều ngưỡng phân loại. Thứ ba, khoảng chênh lệch giữa hiệu năng trên tập huấn luyện và kiểm định overfitting gap khoảng 0.06 ở mức chấp nhận được, phản ánh khả năng khái quát hóa tốt trên dữ liệu chưa thấy. Cuối cùng, Random Forest cung cấp thước đo mức độ quan trọng của các đặc trưng, góp phần nâng cao khả năng diễn giải mô hình và hỗ trợ xây dựng các hàm ý kinh doanh cụ thể.

4.5. Đánh giá chi tiết mô hình Random Forest

Mô hình Random Forest đã tối ưu siêu tham số được đánh giá toàn diện trên tập test thông qua Confusion Matrix, ROC Curve và Classification Report.



Hình ảnh 4. 2: Đánh giá hiệu suất mô hình Random Forest

Confusion Matrix phân tích chi tiết bốn loại kết quả dự đoán. True Positive (TP) là số khách hàng thực sự churn được mô hình phát hiện đúng đây là nhóm doanh nghiệp có thể can thiệp kịp thời. False Negative (FN) là số khách churn bị bỏ sót nhóm tổn kém nhất vì mất khách mà không hay biết. False Positive là số khách không churn nhưng bị cảnh báo nhầm gây lãng phí chi phí tiếp cận nhưng chấp nhận được. True Negative là số khách không churn được dự đoán đúng.

ROC Curve với AUC 0.84 cho thấy mô hình có khả năng phân biệt tốt giữa hai lớp ở mọi ngưỡng phân loại. AUC = 0.5 tương đương đoán ngẫu nhiên; AUC = 1.0 là mô hình hoàn hảo; AUC 0.84 nằm ở mức tốt cho bài toán thực tế. Điều này cũng xác nhận rằng việc điều chỉnh ngưỡng phân loại xuống dưới 0.5 có thể tăng Recall thêm mà không làm AUC thay đổi.


Precision-Recall Curve: Đây là công cụ đánh giá quan trọng hơn ROC Curve trong bài toán mất cân bằng lớp. PR Curve vẽ mối quan hệ giữa Precision trục tung và Recall trục hoành khi ngưỡng phân loại thay đổi từ 0 đến 1. Chỉ số tổng hợp Average Precision tính diện tích dưới PR Curve, phản ánh chất lượng phát hiện lớp thiểu số. Với Random Forest đạt AP 0.65 trên tập test, mô hình cho thấy khả năng cân bằng hợp lý giữa Precision và Recall cho lớp churn. Quan trọng hơn, PR Curve cho phép doanh nghiệp chọn ngưỡng phân loại tối ưu theo chi phí kinh doanh: nếu ưu tiên không bỏ sót khách hàng có nguy cơ cao (tăng Recall), hạ ngưỡng xuống 0.35–0.40; nếu ưu tiên độ chính xác của cảnh báo (tăng Precision), giữ ngưỡng 0.5. Phân tích PR Curve bổ sung cho ROC Curve một góc nhìn thực tiễn hơn về hiệu năng mô hình trong điều kiện mất cân bằng lớp.

Classification Report chi tiết theo từng lớp: lớp Churn đạt Recall 0.80 và Precision 0.50, F1 0.62. Lớp No Churn đạt Precision 0.90 và Recall 0.80. Sự bất cân xứng giữa Precision và Recall của lớp Churn là đặc trưng của bài toán mất cân bằng lớp và phù hợp với mục tiêu ưu tiên Recall của đề án.

4.6. Feature Importance và Insight kinh doanh

4.6.1. Phân tích Feature Importance từ mô hình Random Forest

Random Forest cung cấp feature importance dựa trên mức giảm impurity trung bình khi chia tách theo từng đặc trưng. Top 15 đặc trưng quan trọng nhất cho thấy mô hình học được những tín hiệu gì từ dữ liệu:



Hình ảnh 4. 3: Biểu đồ đặc trưng quan trọng của các biến

Tenure hay gòn gọi thời gian sử dụng dịch vụ dẫn đầu với Importance Score xấp xỉ 0,190 cao hơn đáng kể so với tất cả các đặc trưng còn lại. Kết quả này phản ánh một quy luật phổ biến trong lĩnh vực viễn thông: khách hàng gắn bó lâu dài với nhà mạng có xu hướng ít rời bỏ hơn, trong khi những khách hàng mới tham gia dịch vụ thuộc nhóm rủi ro cao hơn. Tenure do đó là yếu tố dự báo cốt lõi và có giá trị thực tiễn cao trong thiết kế chiến lược giữ chân khách hàng.

Contract_Two year xếp thứ hai với Importance Score khoảng 0,155, khẳng định rằng loại hợp đồng đóng vai trò quan trọng trong việc ràng buộc hành vi của khách hàng. Khách hàng ký hợp đồng dài hạn hai năm được kỳ vọng có tỷ lệ rời bỏ thấp hơn so với nhóm sử dụng hợp đồng tháng, do các ràng buộc pháp lý và chi phí chuyển đổi cao hơn.

InternetService_Fiber optic và TotalCharges cùng đạt Importance Score dao động quanh mức 0,085–0,090, tạo thành nhóm thứ ba về mức độ ảnh hưởng. Sự xuất hiện của dịch vụ cáp quang cho thấy loại hình dịch vụ Internet có mối tương quan đáng kể với hành vi rời bỏ điều này có thể phản ánh kỳ vọng cao hơn về chất lượng dịch vụ hoặc mức cước phí cao hơn ở phân khúc khách hàng này. TotalCharges tổng chi phí tích lũy có quan hệ mật thiết với tenure, do đó sự xuất hiện đồng thời của hai đặc trưng này là

hợp lý về mặt thống kê, song cũng đặt ra vấn đề đa cộng tuyến cần được xem xét trong các phân tích sâu hơn.

PaymentMethod_Electronic check (~0,070) và MonthlyCharges (~0,063) tiếp tục khẳng định rằng phương thức thanh toán và mức cước hàng tháng là những tín hiệu hành vi quan trọng. Khách hàng sử dụng séc điện tử phương thức kém tiện lợi và ít tự động hóa hơn so với thanh toán thẻ hay chuyển khoản tự động có thể có mức độ gắn kết thấp hơn với dịch vụ.

Contract_One year (~0,053) và OnlineSecurity_Yes (~0,046) hoàn thiện nhóm này. Kết quả nhấn mạnh rằng cả loại hình hợp đồng lẫn việc đăng ký thêm dịch vụ bổ sung đều có tác động có thể đo lường được đến khả năng giữ chân khách hàng.

Các đặc trưng thuộc nhóm cuối, bao gồm DeviceProtection_No internet service, OnlineSecurity_No internet service, OnlineBackup_No internet service, TechSupport_Yes, TechSupport_No internet service, StreamingMovies_No internet service và StreamingTV_No internet service, đều có Importance Score trong khoảng 0,020–0,035. Đáng chú ý là sự xuất hiện dày đặc của các giá trị "No internet service" trong nhóm này cho thấy phân khúc khách hàng không sử dụng dịch vụ Internet cũng mang tín hiệu phân biệt nhất định, mặc dù yếu hơn. Điều này gợi ý rằng tình trạng sử dụng gói dịch vụ tổng thể chứ không chỉ các dịch vụ giá trị gia tăng riêng lẻ có ý nghĩa trong việc phân loại hành vi khách hàng.

Nhìn tổng thể, kết quả phân tích mức độ quan trọng của đặc trưng cho thấy ba nhóm yếu tố chủ đạo tác động đến hành vi rời bỏ: (1) yếu tố thời gian và cam kết hợp đồng (tenure, contract type), (2) yếu tố tài chính (TotalCharges, MonthlyCharges, PaymentMethod), và (3) yếu tố dịch vụ kèm theo (InternetService type, OnlineSecurity). Các yếu tố này phản ánh cả chiều dọc mức độ gắn bó lâu dài lẫn chiều ngang mức độ tích hợp sử dụng dịch vụ trong mối quan hệ giữa khách hàng và nhà cung cấp.

Về mặt ứng dụng, doanh nghiệp có thể ưu tiên các chiến lược khuyến khích khách hàng chuyển sang hợp đồng dài hạn, tự động hóa phương thức thanh toán, và nâng cao trải nghiệm sử dụng dịch vụ Internet đặc biệt ở phân khúc cấp quang nhằm giảm thiểu nguy cơ rời bỏ một cách có hệ thống.

4.6.2. Insight kinh doanh sâu từ Feature Importance

Từ kết quả Feature Importance, có thể rút ra sáu insight kinh doanh quan trọng:

Thứ nhất, tenure là yếu tố quan trọng nhất ($\text{importance} \approx 0.19$). Khách hàng ở giai đoạn đầu vòng đời có nguy cơ rời bỏ cao nhất điều này nhất quán với EDA (tỷ lệ churn cao nhất ở nhóm 0–12 tháng). Insight: ưu tiên chăm sóc 3–6 tháng đầu.

Thứ hai, loại hợp đồng là đòn bẩy giữ chân mạnh. Contract_Two year (≈ 0.154) và Contract_One year đều trong top đặc trưng quan trọng. Khách hàng gắn với hợp đồng dài hạn ổn định hơn hẳn so với nhóm Month-to-month. Insight: chuyển đổi khách sang hợp đồng dài hạn là chiến lược retention hiệu quả nhất.

Thứ ba, nhóm Fiber optic có hành vi churn đặc trưng (≈ 0.088). Đây không nhất thiết là dấu hiệu xấu về dịch vụ, mà có thể phản ánh kỳ vọng cao hơn hoặc mức phí cao hơn. Insight: cần theo dõi riêng trải nghiệm và mức độ hài lòng của nhóm này.

Thứ tư, chi phí (TotalCharges, MonthlyCharges) ảnh hưởng đáng kể. Không chỉ mức giá mà cảm nhận về giá trị nhận được so với chi phí mới là yếu tố cần quản trị. Insight: xem xét gói giá linh hoạt và truyền thông rõ giá trị dịch vụ.

Thứ năm, Electronic check gắn với rủi ro cao hơn. Phương thức thanh toán thủ công có thể phản ánh mức độ gắn bó thấp hơn. Insight: khuyến khích chuyển sang thanh toán tự động.

Thứ sáu, dịch vụ hỗ trợ (OnlineSecurity, TechSupport) tăng khả năng giữ chân. Khách hàng có sử dụng dịch vụ bổ sung thường gắn bó hơn. Insight: đây vừa là cơ hội upsell, vừa là cách tăng retention hiệu quả.

4.6.3. Đề xuất hành động kinh doanh cụ thể

Bảng 4. 3: Đề xuất hành động kinh doanh từ kết quả phân tích

#	Hành động	Nhóm mục tiêu	Mục tiêu
1	Chương trình onboarding & chăm sóc sớm (3–6 tháng đầu)	Khách tenure thấp	Giảm churn giai đoạn đầu
2	Ưu đãi chuyển sang hợp đồng dài hạn (giảm giá / tặng tháng)	Khách Month-to-month	Tăng retention
3	Tối ưu chiến lược giá & value proposition	Khách MonthlyCharges cao	Giảm churn do giá

4	Theo dõi riêng nhóm Fiber optic (survey, hỗ trợ nhanh)	Khách Fiber optic	Giảm churn theo phân khúc
5	Khuyến khích chuyển phương thức thanh toán tự động	Khách dùng Electronic check	Giảm churn
6	Bundle dịch vụ TechSupport & OnlineSecurity	Khách chưa dùng add-on	Tăng retention + doanh thu

Các đề xuất này không chỉ dựa trên bằng chứng từ Feature Importance mà còn nhất quán với kết quả EDA ở Chương 2, đảm bảo tính thực tiễn và khả năng đo lường tác động trong môi trường kinh doanh thực tế

CHƯƠNG 5: KẾT LUẬN & KIẾN NGHỊ

5.1. Tóm tắt kết quả đạt được

Nghiên cứu đã hoàn thành một quy trình phân tích churn khách hàng viễn thông một cách có hệ thống và khoa học. Trong Chương 1, nghiên cứu đã làm rõ bài toán kinh doanh, xác định mục tiêu chính là xây dựng mô hình dự báo churn với trọng tâm vào Recall và AUC, đồng thời nhấn mạnh ý nghĩa kinh tế khi chi phí giữ chân khách hàng cũ thấp hơn nhiều lần so với thu hút khách mới.

Chương 2 tập trung vào khám phá dữ liệu và phân tích. Qua EDA, đã làm rõ cấu trúc dữ liệu, phát hiện sự mất cân bằng lớp nghiêm trọng churn chỉ chiếm 26,5%, đồng thời xác định các yếu tố có tương quan mạnh với churn như tenure, MonthlyCharges, TotalCharges, loại hợp đồng Month-to-month và dịch vụ Fiber optic. Chương 3 trình bày quy trình tiền xử lý dữ liệu chặt chẽ gồm 5 bước: loại bỏ biến không cần thiết (customerID), xử lý 11 giá trị khoảng trắng trong TotalCharges, mã hóa One-Hot Encoding cho biến phân loại, chuẩn hóa StandardScaler cho các biến số, và chia dữ liệu theo tỷ lệ 80/20 có phân tầng (stratify), đảm bảo không xảy ra data leakage.

Chương 4 trình bày chi tiết thực nghiệm và kết quả mô hình hóa. Quy trình xây dựng mô hình được chia thành ba giai đoạn: huấn luyện và so sánh baseline của bốn thuật toán, tinh chỉnh siêu tham số bằng GridSearchCV (5-fold, scoring=recall) kết hợp với class_weight='balanced' để xử lý mất cân bằng lớp, và đánh giá cuối cùng trên tập test thông qua Confusion Matrix, ROC Curve, Precision-Recall Curve và Classification Report.

Tổng thể, nghiên cứu đã đạt được mục tiêu đề ra: xây dựng được mô hình dự báo churn có khả năng phát hiện sớm khách hàng rủi ro với độ chính xác và khả năng giải thích cao, đồng thời cung cấp nền tảng khoa học để chuyển hóa kết quả kỹ thuật thành các chiến lược kinh doanh cụ thể.

5.2. Kiến nghị thực tế cho doanh nghiệp

Dựa trên các phát hiện từ nghiên cứu, có một số kiến nghị cụ thể và khả thi nhằm giúp doanh nghiệp viễn thông giảm tỷ lệ churn một cách hiệu quả.

Thứ nhất, doanh nghiệp cần triển khai ngay chương trình onboarding chuyên sâu trong 90 ngày đầu tiên dành cho khách hàng mới tenure dưới 12 tháng, bao gồm check-

in định kỳ, hỗ trợ kỹ thuật miễn phí và tư vấn cá nhân hóa nhằm tăng sự gắn kết từ giai đoạn sớm nhất.

Thứ hai, nên thiết kế các gói ưu đãi chuyển đổi hợp đồng hấp dẫn giảm 10–20% phí để khuyến khích khách hàng nâng cấp từ hợp đồng Month-to-month lên hợp đồng dài hạn 1–2 năm, vì đây là nhóm có nguy cơ churn cao nhất theo kết quả mô hình.

Thứ ba, áp dụng chiến lược bundling dịch vụ bổ trợ TechSupport và OnlineSecurity kèm ưu đãi dùng thử 3 tháng miễn phí dành riêng cho khách hàng sử dụng Fiber optic nhằm tăng giá trị nhận được và giảm tỷ lệ rời bỏ.

Thứ tư, cần xây dựng và đưa vào vận hành hệ thống cảnh báo sớm dựa trên mô hình Random Forest đã xây dựng, chạy định kỳ hàng tháng để xác định và can thiệp kịp thời với những khách hàng có xác suất churn trên 60%.

Cuối cùng, doanh nghiệp nên thực hiện khảo sát hài lòng khách hàng định kỳ, tập trung vào nhóm Fiber optic, thanh toán Electronic check và tenure dưới 24 tháng nhằm phát hiện sớm các điểm đau dịch vụ và điều chỉnh kịp thời.

Việc triển khai các kiến nghị trên không chỉ giúp giảm tỷ lệ churn mà còn góp phần tăng doanh thu trung bình trên mỗi khách hàng và nâng cao trải nghiệm khách hàng tổng thể. Trong tương lai, doanh nghiệp có thể xem xét tích hợp mô hình vào hệ thống CRM để dự báo thời gian thực và mở rộng nghiên cứu bằng cách thu thập thêm dữ liệu hành vi sử dụng dịch vụ nhằm nâng cao độ chính xác của mô hình.

Bằng cách chuyển hóa các kết quả nghiên cứu thành hành động cụ thể, doanh nghiệp viễn thông sẽ có lợi thế cạnh tranh rõ rệt trong việc giữ chân khách hàng và tối ưu hóa hiệu quả kinh doanh.

TÀI LIỆU THAM KHẢO

- BlastChar (2018). *Telco Customer Churn Dataset*. Kaggle.
<https://www.kaggle.com/blastchar/telco-customer-churn>
- Reichheld, F. F., & Schefter, P. (2000). *The Loyalty Effect*. Harvard Business Review.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning*. Springer.
- Scikit-learn developers. (2023). *Scikit-learn: Machine Learning in Python*.
<https://scikit-learn.org>
- Breiman, L. (2001). *Random Forests*. Machine Learning, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- Cortes, C., & Vapnik, V. (1995). *Support-vector networks*. Machine Learning, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B. (2012). *New insights into churn prediction in the telecommunication sector: A profit driven data mining approach*. European Journal of Operational Research, 218(1), 211–229.
<https://doi.org/10.1016/j.ejor.2011.09.031>
- Davis, J., & Goadrich, M. (2006). *The relationship between Precision-Recall and ROC curves*. Proceedings of the 23rd International Conference on Machine Learning (ICML), 233–240. <https://doi.org/10.1145/1143844.1143874>
- He, H., & Garcia, E. A. (2009). *Learning from imbalanced data*. IEEE Transactions on Knowledge and Data Engineering, 21(9), 1263–1284.
<https://doi.org/10.1109/TKDE.2008.239>